

在 vqe 中做一下这篇文章的 scaling law 的问题

目录

1	文献内容	1
2	VQE 与 NQS 二者之间的区别与怎么等价处理	4
3	学习实验	5
4	验证实验	7
4.1	实验设计	7
4.2	预实验	9
4.3	实验一	10
4.4	实验二	11
4.5	实验三	13
4.6	实验四	13
4.7	实验小结	14
5	正式实验	14
5.1	单 N 的 V-score vs f 关系图与 α 的趋势图	15
5.2	实验小结	17
5.3	改进安排	18
6	附录	18

1文献内容

核心内容:该篇文献主要分析深度学习的“scaling laws”是否适用于神经网络量子态（NQS 这一变分量子多体方法）

研究对象：用 Vision Transformer 波函数求解二维 J1-J2

Heisenberg 模型的基态，覆盖四种情形：

- 正方 Heisenberg ($J_2/J_1=0$ ，无阻挫，Néel 序)
- 正方 J1-J2 ($J_2/J_1=0.5$ ，强阻挫，自旋液体)
- 三角 Heisenberg ($J_2/J_1=0$ ，几何阻挫， 120° 序)
- 三角 J1-J2 ($J_2/J_1=0.125$ ，更强阻挫，自旋液体)

处理思路：

1).哈密顿量构造：

$$\hat{H} = J_1 \sum_{\langle i,j \rangle} \mathbf{S}_i \cdot \mathbf{S}_j + J_2 \sum_{\langle\langle i,j \rangle\rangle} \mathbf{S}_i \cdot \mathbf{S}_j$$

然后构造了四种模型，这四个模型的物理上的阻挫越强，基态包含的量子纠缠和表示复杂度就越高。变分神经网络处理就越难。

那我们目的是什么，找基态，也就是求解薛定谔方程的最小特征值与对应的特征向量。

$$\hat{H} |\Psi\rangle = E_0 |\Psi\rangle$$

2).变分法与人工智能神经网络波函数的提出 (NQS)

如果存储完整的向量，希尔伯特空间维度会指数级别爆炸，所以做法是通过参数化的函数去逼近振幅。

通过一个黑盒函数 (θ)，通过调整这个参数会输出一个一个不同的复数，也就是对应的波函数的振幅。

振幅就决定了在变分蒙特卡洛中哪些采样比例高，哪些采样比

例小，从而决定最后计算的能量平均值。

3). 黑盒优化和损失函数

黑盒优化与经典很一样，也就是看哪个方向的梯度下降更快

损失函数有很多可以参考的值，核心是随着越靠近最低值、基态，值越小。

核心结论：

1. V-score（一种衡量变分态精度的无量纲量，类似 loss）

随训练计算量 f 呈幂律衰减： $V\text{-score} = A \cdot f^{(-\alpha)} \cdot N^\beta$

2. 对不同系统尺寸（ 12×12 到 20×20 ），通过适当重标定计

算量 $fN^{(-\beta/\alpha)}$ ，数据能坍缩到同一条曲线上——说明

Transformer ansatz 具有 "size consistency"（尺寸一致性）

3. 拟合发现 $\alpha \approx \beta$ ，这意味着 $f \approx aN$ （线性区）时，V-score

与 N 无关

4. 指数 α 随阻挫程度系统性下降： $\alpha=1.29$ （正方

Heisenberg） $\rightarrow 0.86$ （正方 J1-J2） $\rightarrow 0.54$ （三角

Heisenberg） $\rightarrow 0.40$ （三角 J1-J2），即阻挫越强，单位计

算量带来的精度提升越慢

5. α 对架构选择（patch size、是否加对称性）robust，只影

响前置因子 A

所以这些结论也是我尽量要靠近分析的，但是在 NQS 中与在 VQE 中一些概念需要替换分析，指标不一样

2VQE 与 NQS 二者之间的区别与怎么等价处理

变分量子求解器 (VQE)

VQE 是一种量子-经典混合算法。它直接利用量子比特的物理状态来表示波函数。通过设计量子线路（如基于化学激发的 UCC 拟设，或硬件高效的 Hardware-Efficient 拟设），调节其中的逻辑门参数，在量子计算机上直接测量出能量期望值，然后把数据传给经典优化器进行参数更新。

神经量子态 (NQS)

NQS 是由 Carleo 和 Troyer 在 2017 年提出的一种经典变分蒙特卡洛 (VMC) 的升级版。它用神经网络（最初是受限玻尔兹曼机 RBM，现在广泛使用 CNN、Transformer 等）来作为一个“函数逼近器”。

输入一个自旋组态 $\sigma = (\sigma_1, \sigma_2, \dots, \sigma_N)$ ，神经网络输出该组态对应的复数振幅 $\psi(\sigma)$ 。它完全运行在 GPU/CPU 上，通过经典随机采样和随机重整化 (Stochastic Reconfiguration) 等方法来优化网络参数。

关于 V-score:

V-score 这个定义可以不变，是从哈密顿量出发，反应它距离最终优化状态的距离

关于计算量 f:

F 是反应的总算力

所以在 NQS 中的定义是： $f = (\text{单次前向 FLOPs}) \times (\text{采样数 } M) \times (\text{优化步数 } N_{\text{opt}})$

在 VQE 中的定义是： $f = (\text{单次电路评估的门数/深度, 反映线路复杂度}) \times (\text{每次能量估计的测量次数 shots}) \times (\text{优化迭代步数})$

3学习实验

实验思路：

构造一个简单的 2-qubit 的横场 Ising 模型（TFIM），感受 VQE 的原理和整个架构。

代码思路：

1.Hamiltonian 定义： $H = -J \cdot Z_0 Z_1 - h \cdot (X_0 + X_1)$ ，用 Pauli 算符的线性组合表示，这是 J1-J2 Heisenberg Hamiltonian 的简化版本，也有着随着 h 的增大比特之间的相互纠缠与干预作用越来越强


2.计算基态能量：因为 qubits 很少，可以直接通过对角化计算出基态能量值

3.构造量子电路，也就是黑盒函数：我们变分拟合电路（Ansatz）的结构是：旋转门+纠缠门+旋转门,参数就是由两个旋转门提供，训练就是训练这两个旋转门的参数，看怎么旋转，旋转多少度

4.计算量子电路处理后的结果，获取测量值，在每次实验中，

经典优化器（`qml.AdamOptimizer`）通过量子计算机算出的梯度，不断调整 `params`，驱使 `circuit_energy` 的输出值（能量）越来越低。

5.测量结果分析



1.对于 2-qubits 的问题：即使只有一层电路，只要 steps 合理，也能把误差压到精度范围内。说明当尺度过小，无法找到有意义的结果。

2.当电路层数很少时候，瓶颈主要在优化步数，不在表达能力（在 1-3 层时候，步数大于 150，结果非常接近准确值）

3.训练步数和训练层数要匹配，当训练步数太少，训练层次多反而误差会变大（在 steps=100 时候，层数为 3 层时候反而误差变大了）

4.关于层次 4，训练步骤也很大，突然出现的反弹，现在认为是

seed 值只设置了一个的原因。

4 验证实验

4.1 实验设计

通过 1D 的 J_1 - J_2 海森堡链模型进行量化物理的缩放定律实验

1.1D J_1 - J_2 海森堡链模型的物理基础。

我们实验模拟的是一圈排成排的量子自旋，然后彼此之间有自旋相互作用。

J1（最近邻）：相邻比特之间的互相拉扯（0 与 1）

J2（次近邻）：隔一个比特之间的互相拉扯（0 与 2）

周期性边界条件：首尾相互连接，围成一个圆（环形）。

随着 J2 的相对值越来越大，系统的量子阻挫就会越来越复杂。

2.构造哈密顿量

$$H = J_1 \sum_i \mathbf{S}_i \cdot \mathbf{S}_{i+1} + J_2 \sum_i \mathbf{S}_i \cdot \mathbf{S}_{i+2}$$

目前这个哈密顿量量子电路识别不了，需要转换成能识别的，也就是用泡利算符进行表示。

$$\mathbf{S}_i \cdot \mathbf{S}_j = \frac{1}{4}(X_i X_j + Y_i Y_j + Z_i Z_j)$$

并且加入环形边界，解决讨厌的边界效应，有利于分析我们的主要问题。

3. 环形量子电路 (Ansatz)

我们的电路门组成是 RY+CNOT (环形纠缠) +RY

Params: $n_layers \times n_qubits \times 2$

4. V-score 指标评选

当比特数很大时候，就不能算出基态的能量值，这时候就得换一个指标。在线性代数和量子力学中有一个定理：如果一个量子态 $|\psi\rangle$ 是哈密顿量 H 的本征态（比如基态），那么在这个状态下测量能量，其方差 (Variance) 必然为 0。

为了消除总比特数 N 与总能量大小对指标的干扰，进行无量纲处理：

$$V_score = \frac{N \cdot \text{Var}(H)}{\langle H \rangle^2}$$

5. 反向传播与优化

第一步参数位移规则：把这个参数向前、向后各旋转一个固定的角度（通常是 $\pi/2$ ），然后做减法。

第二步：PennyLane 在底层完成量子与经典的往返旅行（对所有参数依次执行第一步，将结果传给 Adam 优化器）

第三步经典优化器更新参数：这里的优化器有两个特殊地方一个是动量（如果有几步都是往某个方向走，就会冲过去），另外一个自适应学习率（对于参数梯度剧烈振荡的，会自动踩刹车，对于

某个参数梯度很微弱的，会踩油门）

4.2 预实验

1. 改 J_2 值：没有明显发现阻挫对实验结果的影响，好像值 J_2 越大，V-score 得分还越高，更容易训练
2. 改 n_{qubits} ：实验结果表面，随着 n_{qubits} 的增加，精度变低，训练变难
3. 改 seed ：发现随机种子数对实验结果的影响很大，有些会相差一个数量级。

预实验实验分析：2 和 2 实验符合我们的预期，也符合文献内容，但是对于实验一的异常，分析可能有以下原因：

1. 物理模型本身的阻挫复杂度，并不能简单等同于变分量子算法的优化难度。

由于实验采用的是缺乏物理先验（带有距离衰减的几何先验）的硬件高效型 Ansatz（RY+CNOT），其在 $J_2 = 0$ 的高度对称相区内，可能遭遇了严重的局部极小值卡顿（能量景观过于复杂）；而阻挫 J_2 的引入可能重塑了参数空间的能量景观（Energy Landscape），使其更易于经典优化器进行梯度下降。可能 Ansatz 自身的表达能力特征与物理基态的实际结构之间，存在着非线性的复杂耦合关系。

2. 比值变化时，能量的理论值也会变化（ E_{exact} ），而此时 V-score 还能不能衡量精度和训练难度得思考。

此时需要看看不同 J_2/J_1 下的 E_{exact} 和 E_{final} 实际数值，看看是不是"V-score 看起来小"只是因为分母 $\langle H \rangle^2$ 变大了，而绝对误差 $|E_{\text{final}} - E_{\text{exact}}|$ 其实没有变小。

4. 预实验的 seed 跑太少了，需要设计多个 seed 值

4.3 实验一

固定($n_{\text{qubits}}=4, n_{\text{layers}}=4$)，对 $J_2/J_1 \in \{0, 0.25, 0.5\}$ ，每个跑 5 个 seed (0-4)，打印出每次的: $E_{\text{exact}}, E_{\text{final}}, \text{abs_error}, V_{\text{score}}$

n_qubits	n_layers	J2/J1	seed	E_{exact}	E_{final}	abs_error	V_score
4	4	0	0	-1.993614114	-1.993614114	6.385886e-03	1.868569e-02
4	4	0	1	-1.998751295	-1.998751295	1.248705e-03	3.497995e-03
4	4	0	2	-1.999840683	-1.999840683	1.593174e-04	4.737190e-04
4	4	0	3	-1.999869428	-1.999869428	1.305719e-04	3.224797e-04
4	4	0	4	-1.9999837	-1.9999837	1.630055e-05	3.931573e-05
4	4	0.25	0	-1.749998216	-1.749998216	1.784269e-06	6.191143e-06
4	4	0.25	1	-1.749997944	-1.749997944	2.055556e-06	7.283955e-06
4	4	0.25	2	-1.749998153	-1.749998153	1.847312e-06	6.883250e-06
4	4	0.25	3	-1.749931274	-1.749931274	6.872625e-05	2.401934e-04
4	4	0.25	4	-1.749270773	-1.749270773	7.292267e-04	2.080887e-03
4	4	0.5	0	-1.499848948	-1.499848948	1.510525e-04	6.499933e-04
4	4	0.5	1	-1.499995376	-1.499995376	4.624074e-06	2.395251e-05
4	4	0.5	2	-1.499877459	-1.499877459	1.225407e-04	6.190208e-04
4	4	0.5	3	-1.49994592	-1.49994592	5.408026e-05	2.524938e-04
4	4	0.5	4	-1.5	-1.5	1.532108e-14	5.526444e-14

数据分析: abs_error 在很多行小到 10^{-5} 甚至 10^{-14} ，"VQE 几乎完美命中 exact 值"，在 $J_2/J_1=0.25$ 和 0.5 （理论上应该是更难优化的阻挫区域）反而比 $J_2/J_1=0$ 更容易，这不符合任何物理预期。

结果分析:

在 4-qubit 周期边界条件下，"次近邻"($i, i+2$)实际上和($i+2, i$)是同一对，而且每个 qubit 的次近邻正好是它的"对角"位置——在 4 格点的环上，次近邻连接本身又构成了一个更小的环。或者更直接

说： $J_2/J_1=0.5$ 时基态能量是双重简并的(-1.5, -1.5)，且这两个能量正好是简单的有理数(-3/2 和-7/4)——这是一个高度对称、退化、"太简单"的小尺寸效应，不是真实的 J1-J2 Heisenberg 物理（真实的 J1-J2 链物理，包括 Majumdar-Ghosh 点的特殊简并性，需要更大的 N 才能体现，且 MG 点严格在 $J_2/J_1=0.5$ 时基态是精确的双重简并 dimer 态，这其实在数学上是对的，但 4 个格点太小，物理图像还没展开）。我们接下来因该提高 qubits 的数值大小。

4.4 实验二

固定($n_qubits=8, n_layers=4$)，对 $J_2/J_1 \in \{0, 0.25, 0.5\}$ ，每个跑 5 个 seed (0-4)，打印出每次的： $E_exact, E_final, abs_error, V_score$

A	B	C	D	E	F	G	H	I
n_qubits	n_layers	J2/J1	seed	E_final	E_exact	abs_error	V_score	
6	4	0	0	-2.543732	-2.802775638	2.590432e-01	5.112050e-01	
6	4	0	1	-1.977412	-2.802775638	8.253637e-01	3.301317e-01	
6	4	0	2	-2.695962	-2.802775638	1.068135e-01	2.291411e-01	
6	4	0	3	-2.56086	-2.802775638	2.419154e-01	5.188537e-01	
6	4	0	4	-2.465338	-2.802775638	3.374379e-01	5.389403e-01	
6	4	0.25	0	-2.300472	-2.505199322	2.047272e-01	1.800037e-01	
6	4	0.25	1	-1.761238	-2.505199322	7.439613e-01	1.974929e-01	
6	4	0.25	2	-2.402848	-2.505199322	1.023513e-01	2.635442e-01	
6	4	0.25	3	-2.321394	-2.505199322	1.838050e-01	2.516883e-01	
6	4	0.25	4	-2.398372	-2.505199322	1.068273e-01	2.598475e-01	
6	4	0.5	0	-2.25	-2.25	3.566036e-13	8.200189e-13	
6	4	0.5	1	-1.673014	-2.25	5.769857e-01	5.830943e-02	
6	4	0.5	2	-2.249754	-2.25	2.463315e-04	7.952196e-04	
6	4	0.5	3	-2.249997	-2.25	2.524561e-06	1.082284e-05	
6	4	0.5	4	-2.249924	-2.25	7.606779e-05	2.477478e-04	

数据分析：在 $J_2/J_1=0$ 和 0.25 这两组数据，看起来"满足论文规律"，但实际上两组数据都没有真正收敛，与其说是在比较"不同阻挫下的优化难度"，不如说是在比较"两组都很差的随机结果"——这个对比目前还不可靠。说明当 qubits 的个数达到 6 个时，需要更多层数才能让 ansatz 有足够的表达能力；

对于 $J_2/J_1=0.5$ 那一组的"混乱"——可能是 Majumdar-Ghosh 点的真实物理信号。注意 $E_{\text{exact}}=-2.25$ ，且 $\text{seed}=0、2、3、4$ 都精确或接近精确收敛（误差到 $10^{-13} \sim 10^{-4}$ ），唯独 $\text{seed}=1$ 完全没收敛(误差 0.58)。这是一个非常典型的"优化卡在局部极小"现象，而且 $J_2/J_1=0.5$ 正是 1D J_1 - J_2 链的 Majumdar-Ghosh(MG)点——在这一点上，精确基态是两个简并的 dimer 态的叠加。MG 点的损失地形(loss landscape)中存在两个等价但分离的全局最小值（对应两种 dimer pattern），优化器从不同初始点出发，可能掉进其中一个的"盆地"，也可能卡在两者之间的鞍点附近——这可能就是 $\text{seed}=1$ 的情况。这正是"阻挫导致优化更难、 α 更小"这一物理图像在小系统上的具体表现。

关于 $J_2/J_1=0.5$ 收敛，而其他两组没有收敛这里还暴露了一个物理复杂度与电路复杂度之间的不对应性：

物理上： $J_2/J_1=0.5$ 阻挫最强，基态最"复杂"（从凝聚态物理的角度，比如纠缠熵、关联函数等）

电路上： $J_2/J_1=0.5$ 的基态恰好是短程 dimer 乘积态，hardware-efficient ansatz 很容易表示

根据这个实验的结果，我们可以设计下面两个实验，第一个是把 n_{layers} 从 4 提高到 8；对 $J_2/J_1=0.5$ 多跑几个 seed，看看成功收敛与卡住的比例。

4.5 实验三

固定($n_{\text{qubits}}=6$),对 $n_{\text{layers}}=6,8,10$, 对 $J_2/J_1 \in \{0, 0.25, 0.5\}$, 每个跑 5 个 seed (0-4), 打印出每次的: $E_{\text{exact}}, E_{\text{final}}, \text{abs_error}, V_{\text{score}}$

	n_{layers}	$J_2/J_1=0.0$	$J_2/J_1=0.25$	$J_2/J_1=0.5$
	6	197.35	20.07	52.63
	8	5.21	5.23	318.39
	10	26.32	13.75	26.17

V-score 每一组最大值与最小值之比

$L=6, J_2/J_1=0$ 时: **174** 倍的差距 (3 个数量级)

$L=8, J_2/J_1=0.5$ 时: **204** 倍的差距

这里反应了 VQE 常见的难题, 噪音太大, 单次 VQE 的优化结果像碰运气, 而论文里面的方法是对每个配置跑多次的结果取最好的两次平均值的结果, 过掉卡在局部最小值的坏结果。

4.6 实验四

固定($n_{\text{qubits}}=8, n_{\text{layers}}=8$), 对 $J_2/J_1 \in \{0.5\}$, 每个跑 21 个 seed (0-20), 打印出每次的: $E_{\text{exact}}, E_{\text{final}}, \text{abs_error}, V_{\text{score}}$

实验分析:

$7e-5, 3e-4, 4e-4, 7e-4, 1e-3$, $\leftarrow$ 最好的 5 个 (真正收敛)

$1e-3, 2e-3, 3e-3, 6e-3, 6e-3$, $\leftarrow$ 中等

8e-3, 1e-2, 1e-2, 1e-2, 1e-2, $\leftarrow$ 部分收敛

2e-2, 4e-2, 4e-2, 4e-2, 5e-2, 7e-2 $\leftarrow$ 基本没收敛

这里印证了我们之前的分析，不是连续分布，有明显的两群：
约 10 个 seed 收敛到 10^{-3} 以下，约 11 个卡在 10^{-2} 以上。这正好印证了
了我们之前分析的 **MG 点双简并基态** 导致的"双盆地"优化地形——
优化器要么掉进一个 dimer pattern 的盆地（成功），要么卡在两个盆地
之间的鞍点（失败）。

4.7 实验小结

结合前面四个实验的结果，我们现在有两个思路可以选择：

1. 每个配置跑 10 个 seed，取最好的两个的均值作为该点的 V-score。但是数据噪音过大，适合初步探索。
2. 换一个更加稳定的优化器，提升成功率。

5 正式实验

实验目的：

检验论文里在 NQS（Transformer 做变分量子态）上发现的 scaling law 规律——V-score 随训练计算量 f 呈幂律衰减($V\text{-score} = A \cdot f^{(-\alpha)} \cdot N^\beta$)，且不同系统尺寸 N 的数据经过重标定能坍缩到一条曲线上——这套框架是否也能在 VQE（参数化量子电路做变分量子态）上成立。

实验设计：

扫描变量:

- N (qubit 数): 4, 6, 8
- n_layers : 2, 4, 6, 8, 10, 12
- $J2/J1$: 0.0, 0.25 (先不做 0.5, 因为 MG 点的特殊性会干扰结果)
- 每个配置跑 10 个 seed, 取最好 2 个的均值

计算量 f 的定义:

$$f = (\text{电路门数}) \times (\text{优化步数})$$

$$\begin{aligned}\text{电路门数} &= n_layers \times (n_qubits \text{个} RY + n_qubits \text{个} CNOT + n_qubits \text{个} RY) \\ &= n_layers \times 3 \times n_qubits\end{aligned}$$

输出:

CSV 文件: 每行是一个($N, n_layers, J2/J1, seed$)配置的结果

自动聚合: 每个($N, n_layers, J2/J1$)取 best-2 均值

最终画图: V-score vs f , 以及 scaling collapse 图

5.1 单 N 的 V-score vs f 关系图与 α 的趋势图


数据表明, 随着变分电路深度的增加, 系统在前期呈现出清晰的幂律下降趋势。但是, 一旦算法精确收敛至极值点附近, 继续加深电路会导致数据出现‘触底反弹’的逆势爬升现象。

这一非物理规律的异常表现主要原因可能源于两点: 一是机器精度地板效应, 即当误差逼近双精度浮点数的极限 (约 10^{-15}) 时, 真


实的物理信号已被随机的数值舍入噪声完全湮没；二是过参数化导致的优化不稳定，过度冗余的参数空间使能量景观变得异常复杂，从而引发了数值层面的收敛恶化。

这种由数值与统计学因素引入的后期噪声并非系统的内在物理属性，若直接进行全段数据回归，将严重污染幂律拟合结果。为此，引入了自动截断机制，以首次触及精度地板或全局极小值点为界，剔除不可信的反弹数据区。

数据分析：



N=4 时候，由于在 layers=4 时候就已经触底，过早被截断，无法耦合分析；N=6，是唯一一组有用的数据，也发现了 V-score 随着 f 的增大而下降的规律；N=8 时，数据完全没有意义，还没有收敛



对于 $N=6$ ，阻挫程度越大， α 的值越大，而且误差棒很大，说明目前单个 N 、单组 seed 数量下的 α 估计噪声很大，"阻挫增大 α 减小" 这个趋势还谈不上稳健确立，需要更多 N 点和/或更多 seed 支撑才能下结论。

5.2 实验小结

- VQE 框架跑通了：**从 2-qubit TFIM 到 N -qubit J_1 - J_2 Heisenberg 链，hardware-efficient ansatz + Adam 优化器，能正确收敛到 exact ground state（在合适的 layers/steps 配置下）。
- score、f 的定义都已经实现**，且换成 TensorCircuit+JAX 后速度提升 4-5 倍，为后续扩大规模铺好了路。
- 暴露了几个关键的方法论问题：**

- 单次 VQE 结果方差极大（同一配置不同 seed 可以差 2-3 个数量级），必须多 seed 取 best-k 均值
 - hardware-efficient ansatz 对不同 N 的"够用"程度差异巨大——
N=4 很快就触底到机器精度，N=6 刚好能看出幂律趋势，
N=8 在当前 layers 范围下完全不收敛
 - Majumdar-Ghosh 点 ($J_2/J_1=0.5$) 因为基态是 dimer 乘积态，
对这个 ansatz 反而"异常简单"，不能简单类比论文里"阻挫越强越难"的结论
4. 目前唯一可用于拟合的是 $N=6$ ， α 随 J_2/J_1 的变化趋势还不稳定（两次实验方向相反），说明数据量/统计量还不够。

5.3 改进安排

1. 让 layers 范围随 N 自适应，把 N=4、6、8 都做到"健康"区间。
2. 换一个更强的 ansatz，让 N=8 也能在合理 layers 内收敛。
3. 缩小范围，只做 N=4、6 两个点把"单 N 幂律"和" α vs 阻挫"这两个子结论做扎实，明确放弃 scaling collapse。

6附录

n_qubits	J2_over_J1	alpha	alpha_err	A	log_A
6	0	2.681637	0.581521449	49096057567	24.61704
6	0.25	3.172606	0.683785531	3.09409E+12	28.76052

实验流程建议

1. 固定一个(N, J2/J1)组合, 用hardware-efficient ansatz, layer数从1到比如8递增, 每个layer数跑VQE优化到收敛 (每个配置跑3次不同随机初始化, 像论文一样取最好的两次取均值)
2. 记录每次的最终V-score和对应的f
3. 对每个N, 画V-score vs f, 应该看到下降趋势
4. 尝试拟合 $V\text{-score} = A f^{(-\alpha)} N^\beta$, 做scaling collapse, 看不同N的曲线能否坍缩到一条线上
5. 改变J2/J1 (阻挫程度), 重复整个流程, 看 α 是否系统性地随阻挫变化

给老师任务的现实建议

- 先用exact statevector模拟 (无shot noise), 把"优化器本身的随机性"作为唯一噪声源, 这样更接近论文的设定 (论文用~1.6M样本, 本质上方差已经很小)
- 之后如果时间允许, 可以加shot noise, 看看 α 对测量次数是否robust (类似论文Fig.5的 M=16384 vs 20480对比)
- N不需要很大, 4-12个qubit的1D链就足够展示scaling collapse的现象
- 用PennyLane或Qiskit都可以, PennyLane对梯度优化更友好

这是个非常好的问题, 而且你的观察是完全正确的——这背后有一个真实的物理原因。

Majumdar-Ghosh点的精确基态结构

J2/J1=0.5这个点叫做**Majumdar-Ghosh(MG)点**, 它的精确基态是两个完全由**最近邻singlet对 (dimer) **构成的乘积态:

$$|\psi_1\rangle = |\text{singlet}(0,1)\rangle \otimes |\text{singlet}(2,3)\rangle \otimes |\text{singlet}(4,5)\rangle$$

$$|\psi_2\rangle = |\text{singlet}(1,2)\rangle \otimes |\text{singlet}(3,4)\rangle \otimes |\text{singlet}(5,0)\rangle$$

其中每个singlet就是 $(|\uparrow\downarrow\rangle - |\downarrow\uparrow\rangle)/\sqrt{2}$, 是两个qubit的Bell态。

这是关键: MG点的基态是相邻qubit对上Bell态的直积, Bell态只需要**一层**RY+CNOT就能精确制备。所以对你的hardware-efficient ansatz来说, MG点的基态反而是结构上**最简单的**——尽管它物理上是"阻挫最强"的点。

为什么J2/J1=0 (无阻挫) 反而更难收敛

J2/J1=0的标准Heisenberg链基态, 用精确对角化写出来是一个跨越**多个qubit的长程纠缠态** (你在2-qubit实验里就看到过, 基态在 $\{|0011\rangle, |0101\rangle, |0110\rangle, |1001\rangle, |1010\rangle, |1100\rangle\}$ 这六个basis态上都有权重, 而且是全局叠加的)。这种长程纠缠需要更多层的CNOT才能建立起来, 所以4层对N=6的Heisenberg链不够用, 但对MG点的dimer态绰绰有余。